

Native-thinking counting mechanism

按 Non-thinking 报告的证据顺序重排：先给结论，再依次检查表征、targeted retrieval、状态写入与传播、终端读取。主文只保留能改变机制判断的结果。


Qwen3-8B · frozen Top-128 Gemma4-E4B · frozen Top-6 formal: 20 discovery / 10 confirmation

generated 2026-08-22T06:10:18.864807+00:00

CONCLUSION FIRST

一条 recurrent counting pathway 已经接上；natural end-to-end sufficiency 仍未证明

两模型都支持同一类局部因果链：targeted heads 检索下一条 city，改变 grammar-specific marker/tail carrier；carrier 写入 commit state；commit state 再改变下一次 targeted query。终端 marker state 在固定 suffix 的受控实验中能恢复 answer count margin，但把全部上下文抹掉后，仅恢复任一单 item 并不能让答案随 k 从 1 走到 10。



Qwen3-8B

recurrent loop: 强 confirmation

Top-128 retrieval、carrier→commit、commit→next query 都有大效应。terminal marker 的局部受控 restoration 为正。

仍开放：free-running answer count-margin 与全上下文擦除后的单点 sufficiency。

Gemma4-E4B

write 与 terminal local bridge: confirmed

Top-6 retrieval、carrier→commit 都成立；commit→next query 对 self control 为正，但对 orthogonal control 较弱。

仍开放：query edge 的 selection specificity 与全上下文擦除后的单点 sufficiency。

允许的主张。 Native-thinking trace 中存在一条可重复干预的 recurrent counting pathway；它不是已证明唯一或排他的 counting circuit。

01 · EXPERIMENTAL CONTRACT

设计与判据

正式因果实验固定使用 discovery seeds 1234–1253 与 confirmation seeds 1254–1263；所有正式 pair plan 都是 outcome-blind，且不使用 selection_rank。单 seed walkthrough 只作 case study。

DISCOVERY

定位与冻结

20 seeds。选择层、head bank、geometry 与 primary estimand。

CONFIRMATION

独立复现

10 seeds。设计不因 partial outcomes 改动。

CLAIM SCOPE

效应优先


正文同时给 mean effect 与 95% CI，但机制判断首先看效应方向、大小和控制组。

Head bank：Qwen Top-128；Gemma Top-6。Gemma K=6 的 selected–random retrieval failure 比 K=8 更大，因此最新主线固定 K=6；旧 K=8 仅属于历史实验。

Trace stream 与 answer query 都表征 count

在 discovery 拟合 PCA16 与分类器后，confirmation 上的 count-balanced accuracy 均明显高于十分类 chance=0.10。它证明 count 可读出，但单独不构成因果链。

图 1 · Confirmation count decoding




Qwen running commit L18: 0.698; answer query L26: 1.000. Gemma running commit L16: 0.808; answer query L34: 0.710.

结论。 count 信息同时存在于循环中的 commit state 与末端 answer state；后续实验判断这些状态是否被 retrieval、write 和 readout 实际使用。

下一条 city 由 model-specific targeted banks 检索

在 next-city query 持续 mask 冻结 selected heads，并与 layer-matched random heads 比较。Qwen 需要宽 bank；Gemma 使用窄 bank。

图 2 · Targeted-bank dose response



纵轴是 retrieval failure rate。Selected 曲线随 K 增大显著上升，而 layer-matched random 保持低位；Gemma 的注册 grid 在 K=6 达到最大 selected-random gap。

Model	Frozen bank	Selected failure	Random failure	Selected – random
Qwen	Top-128	93.1%	3.4%	+89.7 pp
Gemma	Top-6	83.3%	11.5%	+71.9 pp


结论。 targeted retrieval 是强必要边：Qwen Top-128 的 selected-random failure 为 +89.7 pp；Gemma Top-6 为 +71.9 pp。

Targeted retrieval 写入 grammar carrier, 并通过 commit 驱动下一次 query

4.1 targeted bank → carrier → commit

保持 trace tokens 不变, mask selected retrieval bank; 随后在相同 token 位置恢复 clean carrier hidden state, 并与等 token 数、相近深度的普通状态控制比较。

图 3 · Write-edge effect sizes




三组量纲不同, 因此条长只在一行内用于比较模型; 精确 effect 与 CI 见下表。Qwen 效应整体更大, Gemma 效应较小但方向一致。

Edge / control	Qwen confirmation	Gemma confirmation	Interpretation
targeted bank → grammar carrier	+0.228 [+0.138, +0.364]	+0.051 [+0.041, +0.061]	both positive
clean carrier → commit restoration	+0.391 [+0.186, +0.656]	+0.030 [+0.010, +0.053]	both positive
restoration – equal-token nearby control	+9.419 [+7.433, +11.408]	+0.959 [+0.848, +1.064]	position-specific

4.2 commit → next targeted query

把 donor 的完整 commit hidden state patch 到 receiver 的 commit 位置, 然后测量下一次 query 对 donor-successor city 的 targeted-bank attention。Answer query 不参与该干预。

图 4 · Recurrent propagation 与 terminal local bridge



Qwen 的 commit→query 对 self 与 orthogonal controls 都很强。Gemma 对 self patch 为 +0.491，但对 orthogonal control 为 +0.126、CI 跨 0，因此只把 selection-specific query edge称为 directional。


Endpoint	Qwen confirmation	Gemma confirmation	Scope
full commit → next-query targeted attention (vs self)	+4.749 [+2.120, +7.960]	+0.491 [+0.304, +0.688]	direct routing endpoint
full commit → next-query targeted attention (vs orthogonal)	+4.763 [+2.132, +7.866]	+0.126 [-0.046, +0.271]	Qwen strong; Gemma directional/non-specific
marker-core → answer count margin	+2.375 [+0.700, +4.363]	+1.922 [+0.922, +2.938]	fixed-suffix controlled bridge

结论。 Qwen 的 recurrent loop 得到强 confirmation；Gemma 的 write edge 强，但 commit→query specificity 较弱。两者都不要要求 count 只存在于一个低维 subspace：完整 hidden state 的因果效应更符合分布式 state。

Trace 是最终答案的重要信息源；局部 marker bridge 成立，但不是无条件 sufficiency

Broad answer-time heads 可以读取 trace 与 prompt；这里先用 source blank 确认 trace 的自然必要性，再用 grammar-aware terminal restoration 检查 state→answer 的局部因果边。

图 5 · 移除 trace source 后 exact count accuracy



Qwen: 0.97→0.01；Gemma: 0.70→0.12。仅 blank prompt records 不产生同等损伤，说明 answer 主要依赖 trace source，而非回到 prompt 全量重数。

在固定 suffix 的 grammar-span patch 中，marker-core clean-state restoration 对 correct-count margin 为 Qwen +2.375 [+0.700, +4.363]、Gemma +1.922 [+0.922, +2.938]；matched-random specificity 也为正。这支持 terminal marker/tail state 被 answer readout 使用。


Qwen 的边界。 更自由的 targeted-counter / count-margin 实验没有通过 strong gate；distribution、expected count 与 exact count 也没有形成稳定 recovery。因此正文不再把 Qwen final-answer edge 写成普遍的 end-to-end restoration，只保留“固定 suffix 的局部 terminal bridge”。

结论。 final answer 依赖 trace，且 terminal marker state 在受控上下文中有因果作用；尚不能说最后答案只由该 state 或单一 broad bank 决定。

一个 seed 从第 1 个 item 走到第 10 个 item: Native-thinking 不复现旧式单点 sufficiency

固定一个 count=10 confirmation case; 将 prompt records 与完整 trace context 替换为等长普通文本, 再分别恢复第 k 个完整 item、grammar-aware marker/tail carrier, 或等 token 数普通状态。Patch 从 source layer 延伸到最后 decoder block, 但不 patch answer query。

图 6 · Full-context scrub 后的 expected-count path



橙色虚线是理想路径 $y=k$ 。Qwen 三条恢复路径大多停在高 count 区; Gemma 大多停在低 count 区。两者都没有形成 1→10 的对角路径。

Model	Case	Uninformative baseline	Full-item path	Carrier path	Conclusion
Qwen	seed 1254, count 10	candidate=9; $P(10)=0.002$	exact 1/10; $r=-0.39$	exact 2/10; $r=+0.55$	does not walk 1→10
Gemma	seed 1258, count 10	candidate=1; $P(10)=0.002$	exact 1/10; $r=+0.24$	exact 1/10; $r=+0.07$	does not walk 1→10

控制成功。

Clean case 均输出 10; uninformative baseline 分别退化为 Qwen candidate 9、Gemma candidate 1, 且 $P(10)$ 分别仅 0.0015 / 0.0022。

Restoration 失败。

单 item hidden state 不能在擦除的下游 trace 动力学中独立决定答案。V1 只擦 parsed items, 遗漏 trace tail 的答案泄露, 作为 failed-control audit 保留, 不进入结果。

结论。 该 case study 是 descriptive null, 不做群体推断。它区分了 Native 与 Non-thinking: Native count 更像循环状态, 需要后续 trace 配合传播, 而不是一枚可被直接搬到答案端的独立 token code。

最终机制图景

01

Retrieve

Targeted heads 读取下一条 prompt city。Qwen 使用宽 Top-128；Gemma 使用窄 Top-6。

causal necessity

02

Write & commit

检索改变 grammar-specific carrier，carrier 将进度提交到 residual stream。

deform + restore

03

Loop & read

commit 改变下一次 targeted query；终端 state 再被 answer-time readout 使用。

recurrent + conditional terminal

Model	Strongest connected path	Remaining confound
Qwen	Top-128 retrieval → carrier → commit → next query	terminal readout 只在固定 suffix 局部成立；free-running recovery 与 single-seed walk 不成立
Gemma	Top-6 retrieval → carrier → commit；terminal local bridge	commit→query 对 orthogonal specificity 较弱；single-seed walk 不成立

与 **Non-thinking** 的核心差异。Non-thinking 更接近 answer-time broad aggregation + late write; Native-thinking 的主要证据落在 trace 内部的 targeted retrieval 与 recurrent state update。两种模式都可在 answer query 表征 count，但形成 count 的路径不同。

08 · BOUNDARIES AND REPRODUCIBILITY

边界、复现与底层文件

- 本报告证明一条 pathway，不证明唯一性、排他性或所有 grammar 共用完全相同的 heads。
- CI 与 p-value 保留用于审计；正文的“强/弱”判断同时考虑 effect size、控制组和跨 phase 复现。
- 单 seed walkthrough 不进入 discovery/confirmation gate；V2 是在 V1 暴露 trace-tail 泄露后修正的 exploratory control。
- Qwen 与 Gemma 的状态几何、bank 宽度和最后一条边不同，不强行合并成完全同构 circuit。

► 底层报告与证据文件