

OV 如何解释近似垂直的计数轨迹

Realistic NIAH v4 Mechanism Note

Abstract

Realistic NIAH v4 中, prompt 与 answer 的计数轨迹具有较高的关系几何相似度, 但逐步方向近似正交。本文给出一个最小解释: QK 决定从哪里读取, OV 决定读取什么以及写入 residual 的哪个方向。因此, attention 可以成功检索计数信息, 同时把该信息改写到与 prompt 方向近似垂直的 answer 子空间。本文同时给出一个二维例子和三项可证伪实验。

1 现象与结论

在 role-centered 的共同 PCA 空间中, Qwen3-8B L29 的 linear CKA、distance correlation 和 successive-step cosine 分别为 0.798、0.761 和 -0.004 ; Gemma4-E4B L37 的对应数值为 0.798、0.839 和 0.017。前两项较高说明两条轨迹保留了相似的关系结构, 而 step cosine 接近零说明它们的增量方向近似正交。

这两个现象并不矛盾。它们更自然地支持如下解释: prompt 与 answer 表示的是同一个计数变量, 但使用了不同的载体方向。role-centering 只减去 prompt 和 answer 各自的均值, 并不会对齐两个方向。

2 单个 attention head 的计算

设 r_j 是位置 j 的 residual stream, $x_j = \text{LN}(r_j)$ 。第 h 个 head 在查询位置 q 的输出为

$$\alpha_{qj}^{(h)} = \text{softmax}_j \left(\frac{(W_Q^{(h)} x_q)^\top (W_K^{(h)} x_j)}{\sqrt{d_h}} \right), \quad (1)$$

$$o_h(q) = W_O^{(h)} \sum_j \alpha_{qj}^{(h)} W_V^{(h)} x_j = \sum_j \alpha_{qj}^{(h)} M_{OV}^{(h)} x_j, \quad M_{OV}^{(h)} = W_O^{(h)} W_V^{(h)}. \quad (2)$$

因此, head 并不是直接对原始 hidden state 做加权和。QK circuit 通过 $\alpha_{qj}^{(h)}$ 选择读取位置; W_V 从被选位置抽取 head-space 特征; W_O 再把该特征写回 residual stream。即使 QK 精确选中了 needle, 输出方向仍由 $M_{OV}^{(h)}$ 决定, 不必与 prompt 中的原方向平行。

3 二维例子

设计数 c 在 prompt 中由横轴 e_1 承载:

$$p_c = c e_1 = (c, 0)^\top. \quad (3)$$

考虑一个 head dimension 为 1 的最小 head, 并令

$$W_V = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad W_O = \begin{bmatrix} 0 & 1 \end{bmatrix}^\top. \quad (4)$$

这个 head 的三步计算非常直接。

(1) **V 抽取计数标量**。对 prompt 状态 p_c ,

$$v_c = W_V p_c = c. \quad (5)$$

(2) **Attention 聚合标量**。若被读取位置携带系数 c_j , 则 pre-O 聚合为

$$z = \sum_j \alpha_j v_j = \sum_j \alpha_j c_j \equiv \hat{c}. \quad (6)$$

(3) **O 把标量写到纵轴**。

$$o = W_O z = \hat{c} e_2 = (0, \hat{c})^\top. \quad (7)$$

若每个计数条件最终得到 $\hat{c} = c$, answer 轨迹就是

$$a_c = (0, c)^\top. \quad (8)$$

于是 prompt 和 answer 的逐步增量满足

$$\Delta p = p_{c+1} - p_c = e_1, \quad \Delta a = a_{c+1} - a_c = e_2, \quad \cos(\Delta p, \Delta a) = 0. \quad (9)$$

但两条轨迹的任意成对距离完全相同:

$$\|p_c - p_d\| = |c - d| = \|a_c - a_d\|. \quad (10)$$

对中心化后的样本矩阵 P 和 A , 还有 $PP^\top = AA^\top$. 因此在这个理想例子中, linear CKA 和 distance correlation 都等于 1, 而 step cosine 等于 0. 这正是“关系几何相同, 但方向垂直”的最小构造。真实模型还包含背景特征、多 head、MLP 和多层混合, 所以只会近似满足这些等式。

这个例子只解释表示方向的改变, 并不解释计数信号本身如何产生。由于 $\sum_j \alpha_j = 1$, softmax 对完全相同的 needle value 做平均, 本身不能计算 occurrence count。实际模型仍需序数或累计特征、多个 head 的分工, 或 MLP 的非线性组合。

4 如何验证 OV 机制

几何映射。 在训练 split 上估计 LayerNorm 后的 prompt 计数方向 u_p , 并估计 answer residual 中的方向 u_a 。对每个 head 计算

$$r_h = \cos(M_{OV}^{(h)} u_p, u_a). \quad (11)$$

真正承担写回的 head 应具有较高的 r_h , 并显著超过层、范数和秩匹配的随机 head; 该结果还应在 held-out counts 上保持。

分阶段 patch。 分别 patch attention pattern α 、pre-O 聚合

$$z_h = \sum_j \alpha_{qj}^{(h)} W_V^{(h)} x_j, \quad (12)$$

以及 post-O 输出 $o_h = W_O^{(h)} z_h$ 。使用不同计数的 donor 和 recipient, 并加入位置打乱、随机 head 和等范数 patch 作为控制。若机制成立, α 主要改变“读哪里”, z_h 搬运“读到什么”, 而 o_h 应把变化写到 u_a 并推动下游 count readout。

定向因果干预。 从候选 head 输出中删除 answer 方向分量, 或沿该方向注入信号:

$$o_h^- = o_h - \text{Proj}_{u_a}(o_h), \quad o_h^+ = o_h + \beta u_a. \quad (13)$$

删除实验需要等范数的正交方向作为控制。若 OV 假设成立, 删除 u_a 分量应选择性损害计数而非普遍破坏语言能力; 注入应随 β 产生有符号、近似单调的 count 或 logit 偏移。最终分析应冻结后再在 v4.2 到 v4.4、不同模型和相邻层上复现。

5 当前证据边界

现有 V4 几何结果支持“同一个计数关系被重新编码”, 但还不能把该重编码归因到某个具体 OV circuit。L29H3 的高 endpoint share 更像 first-needle locator, 并不自动等于主 counter。决定性缺口仍是 head-output patch、方向投影删除和有符号注入。若只有整层 residual 显示垂直, 而单 head 或小 head 集合不满足上述映射和因果预测, 则更合适的解释是分布式多 head、MLP 或多层组合机制, 而不是单一 OV retrieval head。